서울시 행정동별 상권분석 통합 데이터셋 — 가이드 & 기본 EDA

항목	내용
파일	`data/processed/서울시_행정동별_상권분석_통합.csv` (UTF-8 BOM)
크기	**425행 × 43열** — 1행 = 1개 행정동 (서울 25개 자치구 전체)
기준 시점	수치 지표 2025년 평균 · 추세 2023Q1–2025Q4 · 금융MBTI 2025Q4
기본키	`행정동_코드` (8자리, 유일)
생성	`scripts/merge_commercial_datasets.py` (통합) · `scripts/eda_commercial_merged.py` (이 문서의 차트)
원천	Gemi_pjt 상권분석 키워드(423동, 정성) + Clau_pjt 상권기회 인사이트(425동, 모델·정량)

Part 1. 데이터셋 가이드

1-1. 한눈에 보기

이 데이터셋은 한 동네를 세 가지 눈으로 봅니다.

관점	무엇을 알려주나	대표 컬럼
누가 사는가 (금융MBTI)	주민의 소득·자산·소비·연체 성향	`금융MBTI`, `1인가구비율`, `아파트_평균_시가`
어떤 상권인가 (정성 키워드)	아파트위키 기반 입지·장단점·추천 업종	`상권_유형`, `상권_장점_키워드`, `추천_유망_업종`
돈이 기대만큼 쓰이는가 (모델)	인구·인프라로 예측한 기대 소비 대비 실제 소비, 그 추세	`배율`, `잔차_추세`, `기회_유형`, `업종_공백`

1-2. 컬럼 사전 (43개)

① 행정동 기준 (3)

컬럼	타입	설명	예시
자치구	문자	25개 자치구	강남구
행정동_코드	정수	8자리 행정동 코드 — **조인 키**	11680610
행정동_코드_명	문자	행정동명 (`신사동`은 강남·관악 2곳 → 이름으로 조인 금지)	대치2동

② 금융MBTI (2) — 출처: 키워드 파일

컬럼	타입	설명	예시
금융MBTI	문자	주민 금융 성향 4종 (KMeans k=4)	자산안정형
군집	정수	0 영앤레버리지형 · 1 생활압박형 · 2 자산안정형 · 3 알뜰안정형	2

③ 상권 프로파일 (3)

컬럼	타입	설명	예시
대표_아파트_단지	문자	apt.wiki 기준 핵심 단지 (`-` = 없음)	은마, 래미안대치팰리스
상권_유형	문자	정성 상권 유형 **51종** (키워드 파일)	학원·에듀타운형
상권_원형	문자	수치 기반 상권 원형 **8종** (인사이트 파일)	학원가·에듀형

④ 핵심 키워드 — 정성 서술 (4) — 출처: 키워드 파일

컬럼	설명	예시 (대치2동)
접근성_교통_키워드	역세권·지형·환승·도로망	3호선 대치역·한티역 역세권, 밤 10시 학원가 일대 왕복 차선 마비
상권_장점_키워드	인프라·배후수요 강점	전국 1위 학원가 밀집으로 10대 학생 및 학부모 유동인구 365일 극대화 …
상권_단점_리스크_키워드	소음·공실·주차난 등	야간 픽업 차량으로 인한 극심한 교통정체, 주차난 심각 …
주요_배후수요_특성	핵심 거주·유동 페르소나	초·중·고 수험생 자녀를 둔 4050 학부모 및 강사진

⑤ 키워드 태그 — 3축 해시태그 (3) — 출처: 인사이트 파일. 공백으로 구분, 빈 칸 = 해당 태그 없음

컬럼	설명	예시 (대치2동)
키워드_접근성인프라	역세권·집객시설·몰세권·지형 등	#다중역세권 #집객시설밀집 #주차난
키워드_소비배후수요	자산·청년·직장인·가족·야간/주말 등	#초고자산 #직장인밀집 #학원가·학군
키워드_환경리스크	공실·소음·정체·유출·위축 등	#교통정체 #노후상권 #고임대료 #주말공동화 #소비유출

태그 기준은 `Clau_pjt/report/상권기회_인사이트_보고서.md` 1장 참고.

⑥ 업종 인사이트 (6)

컬럼	출처	설명
추천_유망_업종	키워드	정성 추천 업종
비추천_주의_업종	키워드	입점 리스크 업종
타깃_업종	인사이트	`[데이터]` 업종 공백 기반 추천 + `[현장키워드]` 정성 추천 병기
업종_공백	인사이트	같은 원형 동 중앙값 대비 지출 비중 ×0.75 이하 업종 (최대 2개). 빈 칸 = 공백 없음
업종_강점	인사이트	같은 원형 동 중앙값 대비 ×1.35 이상 업종 (최대 2개). 빈 칸 = 강점 없음
상권_한줄평	키워드	상권 종합 요약

⑦ 상권 기회 — 모델 결과 (10) — 출처: 인사이트 파일

컬럼	타입	설명
유형	문자	초과달성(기대 ×1.5↑) · 기대수준 · 저평가(×0.67↓) · 데이터점검
사분면	문자	수준 × 추세 6분면 + 데이터점검
기회_유형	문자	① 선점형 · ② 유출보완형 · ③ 확장형 · ④ 검증·포화형 · ⑤ 경고(둔화) · ⑥ 주의(위축)
기회점수	실수	0–100. **①·②만 산정**, 나머지 빈 칸
기회순위	실수	기회점수 순위 (1 = 최고). ①·②만
배율	실수	실제 소비 ÷ 기대 소비 (×1 = 기대 수준)
격차금액_분기	실수(원)	실제 − 기대, 분기 평균
잔차_추세	실수	연간 격차 변화 (0.05 = 연 5%p 개선)

컬럼	타입	설명
기회_인사이트	문자	동별 자동 생성 요약 문장
해석주의	문자	배율 극단(×5↑ 또는 ×0.25↓) 경고. 빈 칸 = 정상

⑧ 정량 지표 (13)

컬럼	단위	설명	출처
상주인구 · 직장인구	명	2025년 분기 평균	상권분석서비스
직주비	배	직장인구 ÷ 상주인구	파생
청년비율	0–1	20·30대 상주인구 ÷ 상주인구	상권분석서비스
청년인구비율	0–1	SKT 청년 인구 ÷ SKT 총인구	SKT 시민생활
1인가구비율	0–1	SKT 1인가구 ÷ SKT 총인구	SKT 시민생활
아파트_평균_시가	원	동 내 아파트 평균 시가	상권분석서비스
아파트비중순위	0–1	아파트 세대 비중의 서울 내 백분위 (절대 비율 아님)	파생
지하철역 · 집객시설	개	동 내 시설 수	상권분석서비스
경도 · 위도	WGS84	동 중심 좌표	상권분석서비스 영역

1-3. 결측치 — 빈 칸의 의미

빈 칸 원인	컬럼	행 수	처리 권장
키워드 파일에 없는 2개 동 (둔촌1동·항동)	금융MBTI, 군집, 대표_아파트_단지, 상권_유형, 정성 키워드 4개, 추천/비추천 업종, 상권_한줄평, 청년인구비율, 1인가구비율	2	분석 시 제외하거나 그대로 둠
설계상 산정 안 함	기회점수, 기회순위	246	①·② 외 유형은 점수 없음
해당 없음	해석주의	403	빈 칸 = 정상
	키워드_소비배후수요 · 키워드_환경리스크	50 · 50	해당 태그 없음
	업종_공백 · 업종_강점	41 · 11	두드러진 공백·강점 없음
원천 결측	아파트_평균_시가, 아파트비중순위	1	둔촌1동 (재건축)
`-` **표기** (결측 아님)	대표_아파트_단지	228	대표 단지 미지정

1-4. 사용 전 꼭 알아야 할 6가지

1. **정성 키워드 컬럼은 `상권_유형`에 100% 종속됩니다.** `대표_아파트_단지`·키워드 4개·추천/비추천 업종은 51개 `상권_유형`마다 한 가지 값뿐입니다. 예: `1인청년·원룸배달형` 68개 동(8개 구)은 문장이 모두 같습니다. **동 단위 차이는 태그(⑤)·업종 공백(⑥)·모델(⑦) 컬럼에서 봐야 합니다.**
2. `배율`**은 로그 스케일로 보세요.** 왜도 9.5, 최대 ×67.5(용산2가동). 평균(1.73)은 의미가 없고 중앙값(0.90)을 쓰세요.
3. `해석주의` **22개 동은 집계 착시 가능성.** ×5↑(14곳, 용산2가동·구로3동·역삼2동·소공동 등)은 대형점·본사 매출이 주소로 잡혔을 수 있고, ×0.25↓(8곳, 여의동·압구정동·명동 등)는 인접 거대상권 흡수나 재건축 영향일 수 있습니다.
4. `청년비율` ≠ `청년인구비율`**.** 분모가 다릅니다(상주인구 vs SKT 총인구). 상관 ρ = 0.91로 비슷하지만 재건축 지역에서 갈립니다. 인구 비율 분석에는 SKT 기준(`청년인구비율`, `1인가구비율`)을 권장합니다.

5. `직장인구` ≈ `직주비` (ρ = 0.95). 모델 입력으로 함께 쓰면 다중공선성. `직주비`는 명동(×50)·반포본동(×48)처럼 상주인구가 작은 동에서 폭증합니다.
6. `아파트비중순위` **는 상대 순위입니다.** 원천 `아파트_가구_수`가 전 기간 0이라 다른 아파트 데이터로 대체했고, 일부 단지만 집계돼 절대값을 쓰지 않았습니다. 고가 지역일수록 낮게 나오는 경향(시가와 ρ = −0.48)이 있어 해석에 주의하세요.

1-5. 사용 예시 (pandas)

```
import pandas as pd
df = pd.read_csv("data/processed/서울시_행정동별_상권분석_통합.csv", encoding="utf-8-sig")

# 1) 신뢰 가능한 동만 (데이터점검·해석주의 제외)
clean = df[(df["기회_유형"] != "데이터점검") & df["해석주의"].isna()]

# 2) 선점형 기회 Top 10
clean[clean["기회_유형"] == "① 선점형 기회"].nsmallest(10, "기회순위")[
    ["자치구", "행정동_코드_명", "상권_원형", "배율", "업종_공백", "타깃_업종"]]

# 3) 태그 검색 — 상가 공실 + 소비 유출이 동시에 있는 동
has = lambda col, tag: df[col].fillna("").str.contains(tag, regex=False)
df[has("키워드_환경리스크", "#상가공실") & has("키워드_환경리스크", "#소비유출")]

# 4) 다른 행정동 데이터와 결합 — 반드시 코드로
# other.merge(df, on="행정동_코드", how="left", validate="one_to_one")
```

Part 2. 기본 EDA

2-1. 구조

- **행:** 425 (자치구별 10–27개, 중앙값 16. 최소 금천구 10 · 최대 송파구 27)
- **열:** 문자 24 · 실수 18 · 정수 1
- **중복:** `행정동_코드` 중복 0건. `행정동_코드_명`은 424종(신사동 2곳)

2-2. 범주형 분포

컬럼	분포
금융 MBTI	알뜰안정형 175 · 생활압박형 125 · 자산안정형 63 · 영앤레버리지형 60 · (없음 2)
상권_원형	근린주거형 161 · 가족·아파트단지형 110 · 청년1인·원룸형 47 · 학원가·에듀형 43 · 오피스·업무형 29 · 고자산·아파트형 24 · 광역집객·관광형 7 · 직주혼합형 4
유형	기대수준 266 · 저평가 89 · 초과달성 66 · 데이터점검 4
기회_유형	② 유출보완형 145 · ④ 검증·포화형 94 · ⑥ 주의(위축) 59 · ③ 확장형 45 · ① 선점형 39 · ⑤ 경고(둔화) 39 · 데이터점검 4
상권_유형	51종. 상위 4종(대단지·생활근린형 97, 1인청년·원룸배달형 68, 서민베드타운·생활근린형 55, 역사도심·관광오피스형 32)이 60%. 51종 중 14종은 동 1–2개짜리

태그 빈도 Top 5

축	Top 5
접근성·인프라	#역세권공백 196 · #주차난 176 · #역세권 133 · #환승요충지 125 · #다중역세권 96
소비·배후수요	#2030청년가구 107 · #가성비선호 106 · #야간소비 85 · #주말나들이 85 · #고령층 75
환경·리스크	#노후상권 102 · #소비위축추세 99 · #외부유입한계 97 · #소비유출 89 · #주말공동화 69

→ 서울 행정동의 **46%는 역세권 밖**이고, 가장 흔한 리스크는 **노후 상권과 소비 위축**입니다.

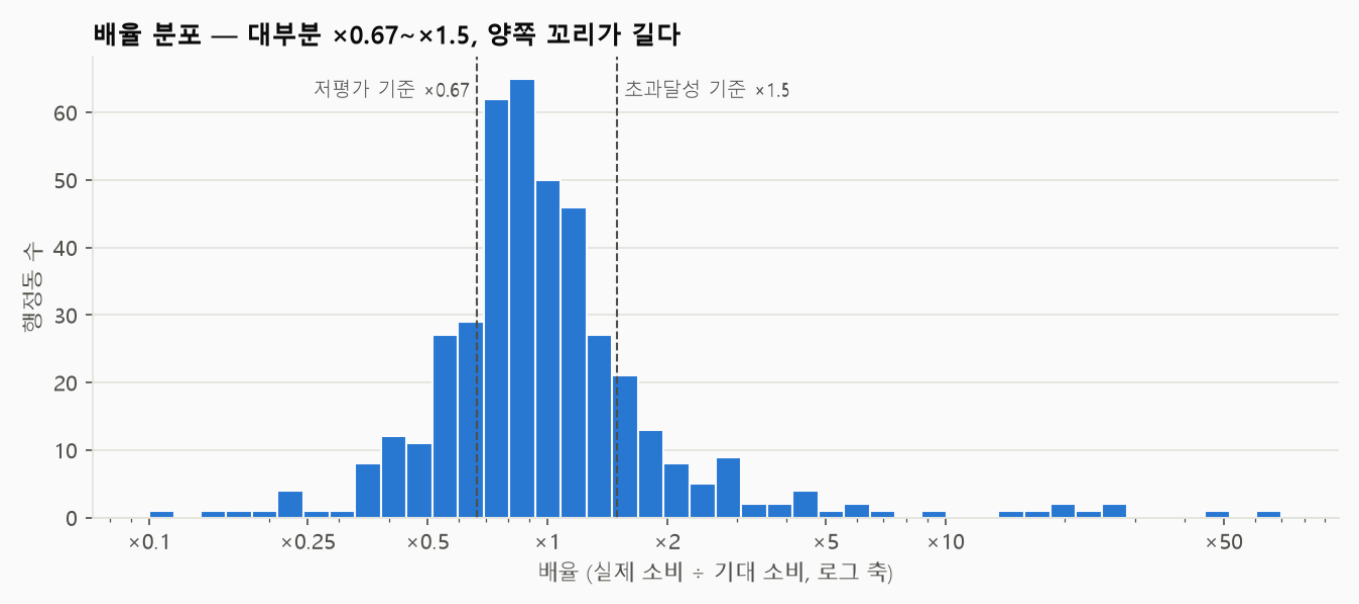
2-3. 수치형 요약

컬럼	최소	25%	중앙값	75%	최대	왜도
배율	×0.11	×0.72	**×0.90**	×1.24	×67.5	9.5
격차금액_분기	−1.07조	−13억	−3.3억	+11억	+1.95조	7.9
잔차_추세	−2.22	−0.045	0.003	0.040	2.35	1.0
기회점수 (n=179)	36.7	51.0	60.8	69.6	90.3	0.1
상주인구	2,454	15,122	19,782	25,006	46,043	0.3
직장인구	0	966	2,159	6,080	220,474	5.2
직주비	0	0.05	0.11	0.27	50.5	9.7
청년비율	0.06	0.25	0.28	0.33	0.66	1.4
청년인구비율	0.18	0.29	0.32	0.36	0.73	1.7
1인가구비율	0.03	0.14	0.18	0.24	0.64	1.3

컬럼	최소	25%	중앙값	75%	최대	왜도
아파트_평균_시가	1.0억	1.9억	2.6억	4.2억	26.7억	2.9
지하철역	0	0	1	1	7	1.8
집객시설	14	81	111	154	542	2.2

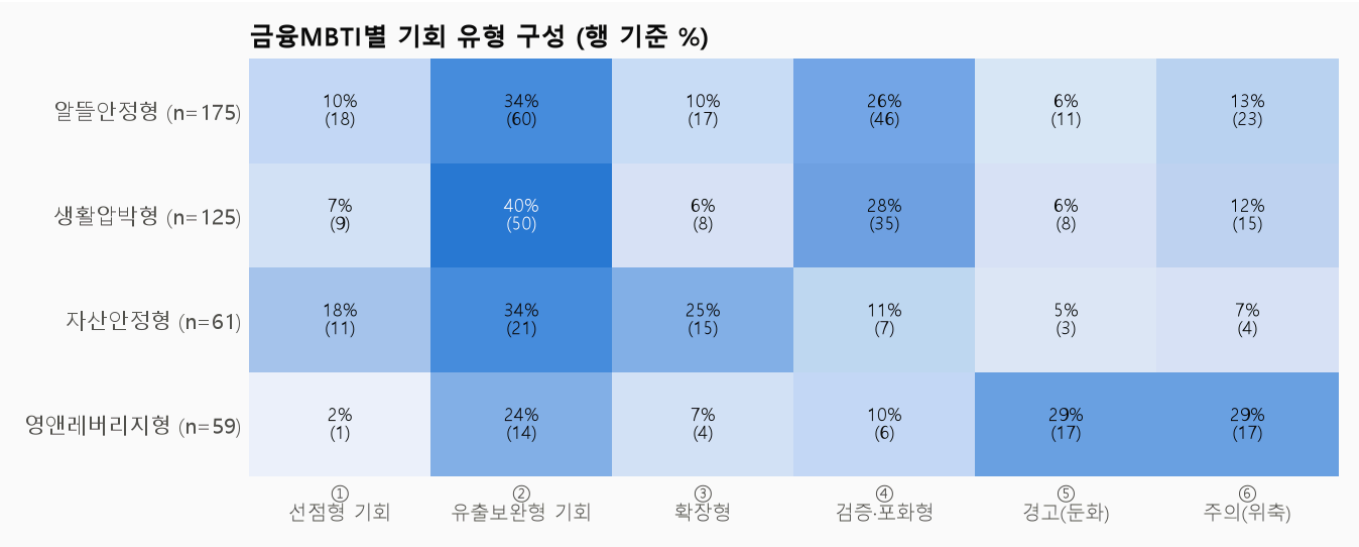
- `직장인구` **= 0인 동 11곳** (일원본동, 잠실7동, 위례동 등). 원천 집계 누락일 가능성이 있어 `직주비`도 0입니다.
- 왜도 2 이상(배율·격차·직장인구·직주비·시가·집객시설)은 **로그 변환 후** 분석하세요.

2-4. 배율 분포



- 로그 축에서 ×0.9 근처에 봉우리가 있는 거의 대칭 분포입니다. 서울 행정동 대부분은 **기대보다 약간 덜** 씁니다 (중앙값 ×0.90). 대형 상권 몇 곳이 소비를 빨아들이기 때문입니다.
- ×10 이상 꼬리(9곳)는 대부분 도심·업무지구이며, 9곳 모두 `해석주의` 대상입니다.

2-5. 금융MBTI × 기회 유형

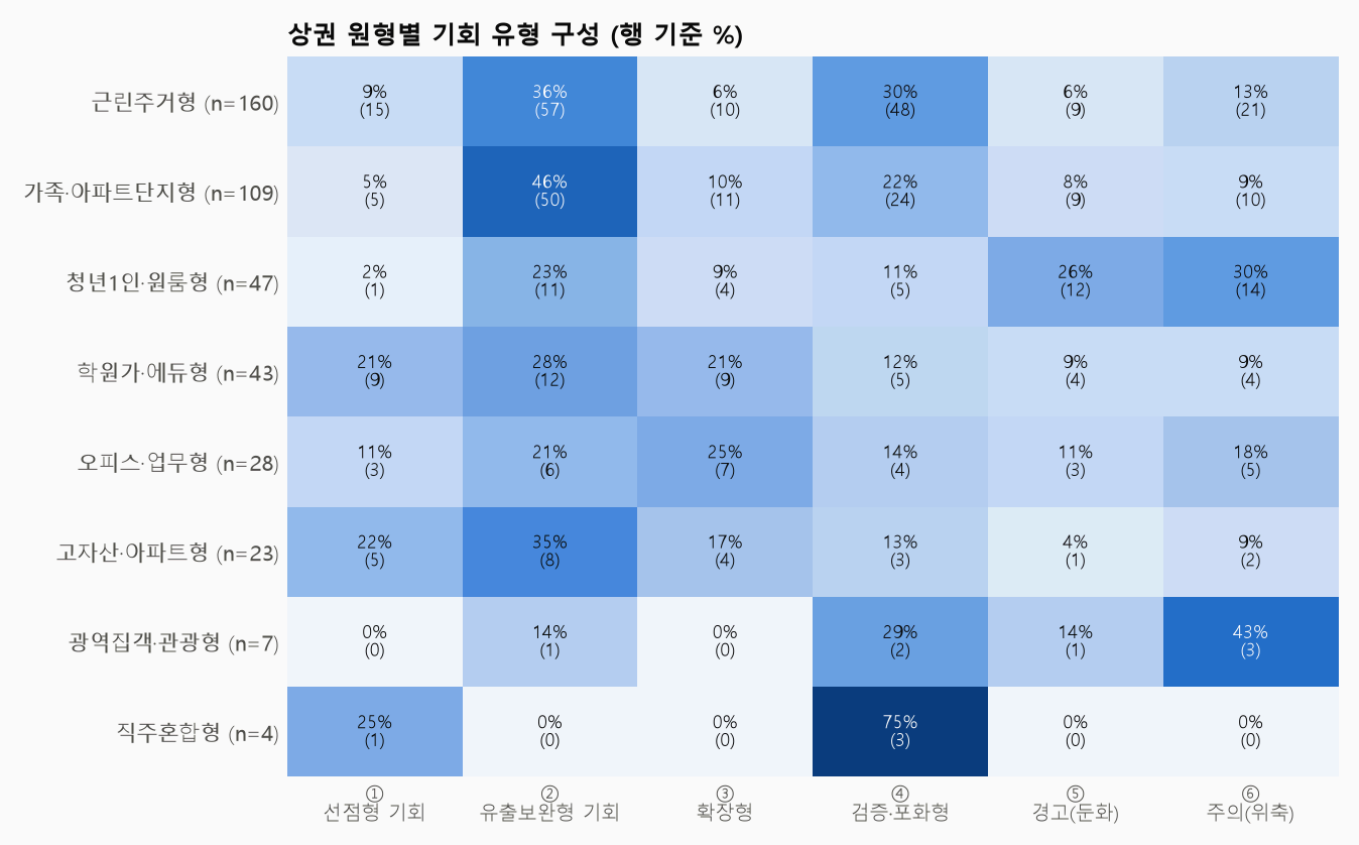


금융MBTI	뚜렷한 특징	잔차 추세 중앙값
영앤레버리지형	**⑤ 둔화 + ⑥ 위축 = 58%** (34/59). 선점형은 1곳뿐	**−6.0%/년**

금융MBTI	뚜렷한 특징	잔차 추세 중앙값
자산안정형	① 선점 + ③ 확장 = **43%**. 위축은 7%	**+3.8%/년**
생활압박형	② 유출보완형 40% — 소비가 동네 밖으로 샘	+0.6%/년
알뜰안정형	고르게 분포	+0.9%/년

→ **주민 금융 성향과 상권 흐름이 연결됩니다.** 청년·1인가구가 많고 연체가 높은 동네(영앤레버리지형)의 상권은 식고 있고, 자산이 탄탄한 동네(자산안정형)의 상권은 좋아지고 있습니다.

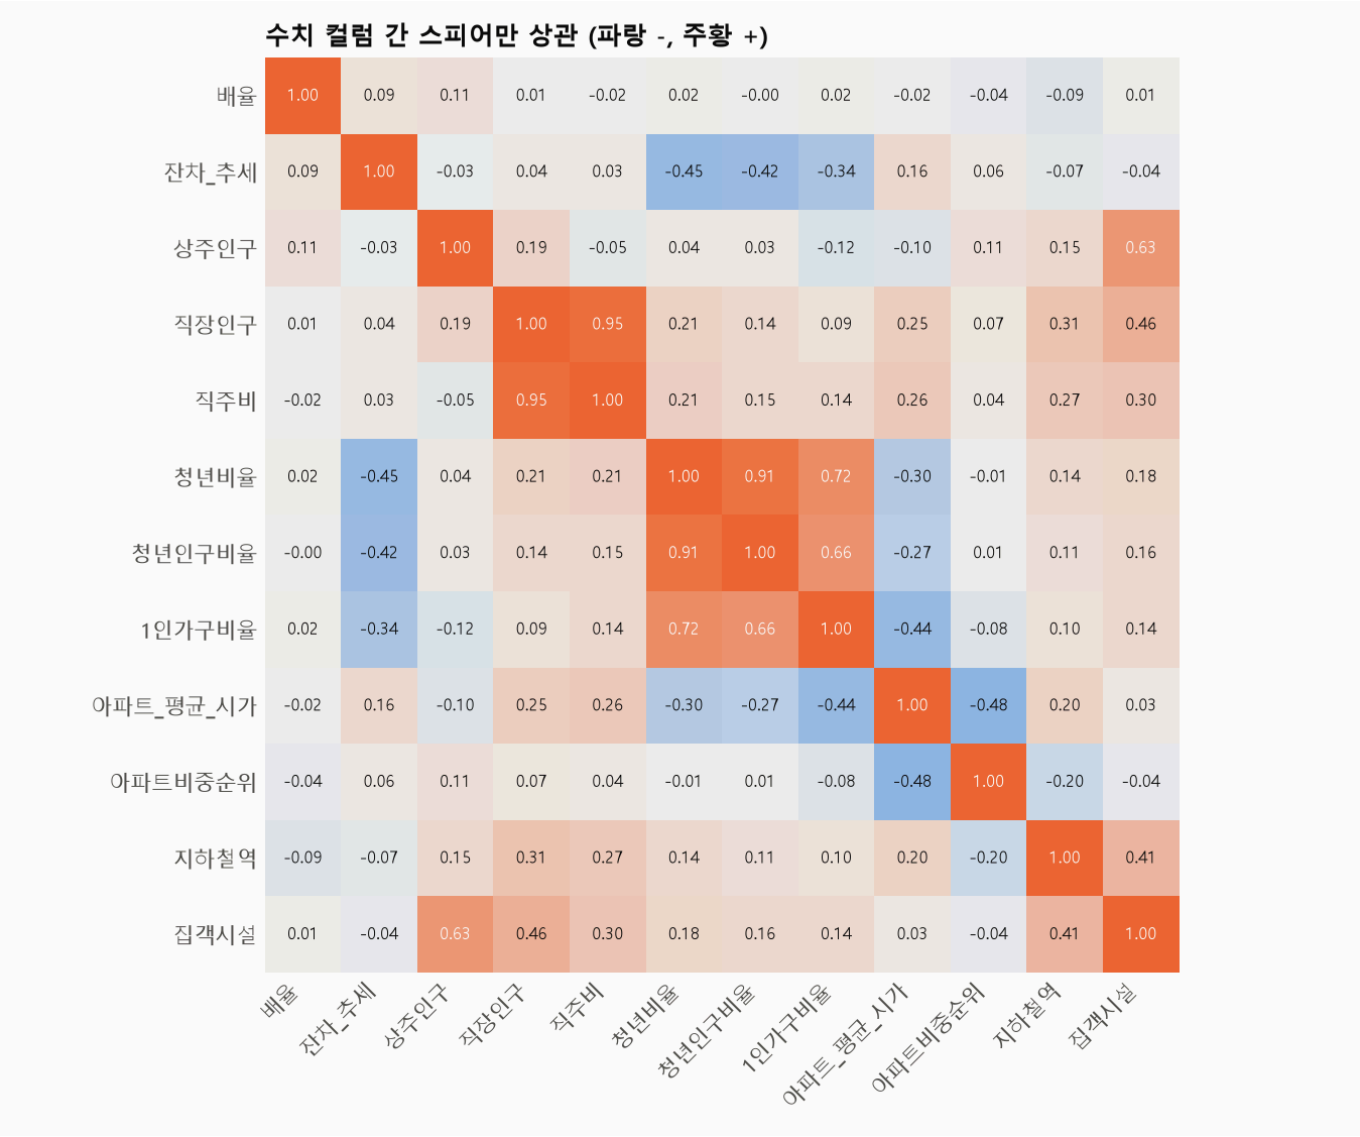
2-6. 상권 원형 × 기회 유형



- **청년1인·원룸형:** ⑤·⑥ 비율이 **55%**로 가장 높습니다(26/47).
- **학원가·에듀형, 고자산·아파트형:** ①·③ 비율이 **40% 안팎**으로 가장 좋습니다.
- **가족·아파트단지형:** ② 유출보완형이 **46%**입니다. 대단지 주민의 소비가 밖으로 새는 패턴입니다.
- **광역집객·관광형**은 7개 동뿐이지만 ⑥ 위축이 43%입니다. 표본이 작아 해석에 주의하세요.

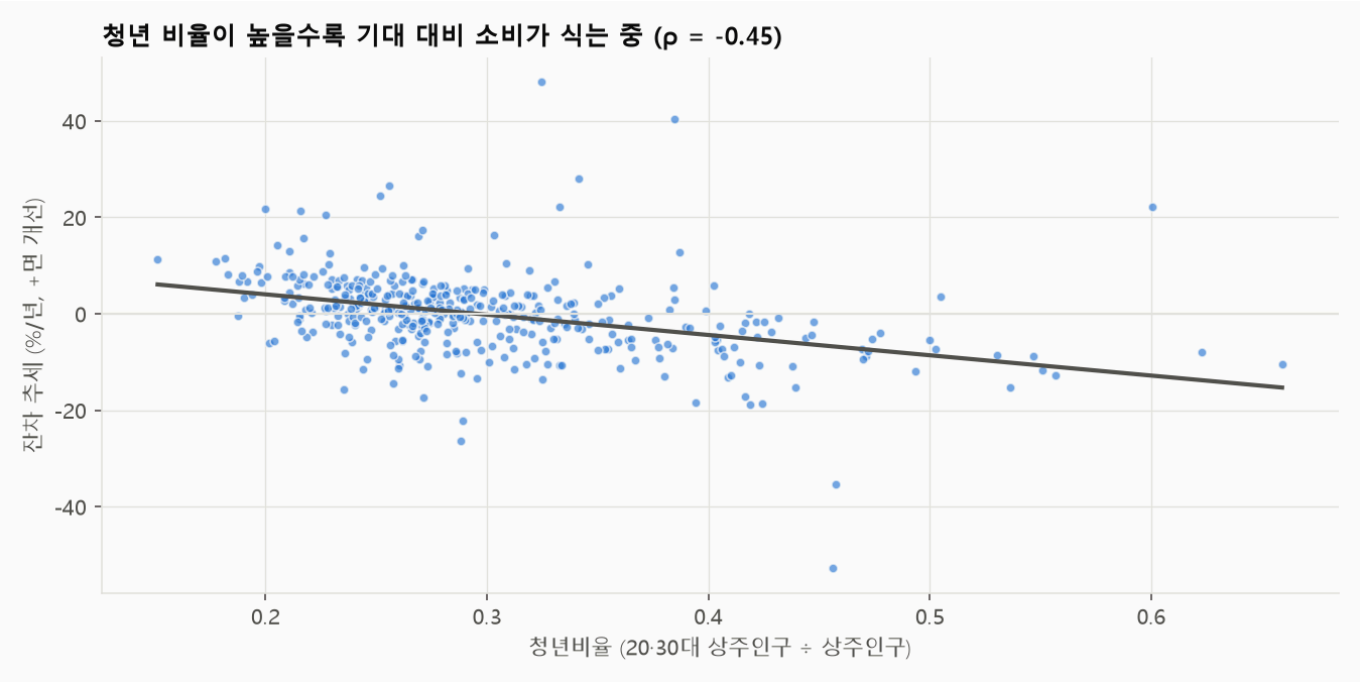
원형과 금융MBTI의 대응: 고자산·아파트형 24곳은 **전부 자산안정형**이고, 청년1인·원룸형은 영앤레버리지형(22)과 알뜰안정형(20)이 대부분입니다. 가족·아파트단지형은 생활압박형(60)이 가장 많습니다. 두 분류는 서로를 설명하지만 겹치지는 않습니다.

2-7. 상관관계



쌍	ρ	해석
직장인구 – 직주비	0.95	사실상 같은 정보. 모델에는 하나만
청년비율 – 청년인구비율	0.91	출처만 다른 같은 개념
청년비율 – 1인가구비율	0.72	청년·1인가구는 함께 움직임
상주인구 – 집객시설	0.63	사람 많은 곳에 시설도 많음
청년비율 – 잔차_추세	**−0.45**	**청년 동네일수록 소비가 식는 중** (아래 2-8)
아파트_평균_시가 – 1인가구비율	−0.44	비싼 동네일수록 가족 가구
배율 – 모든 입력 변수	|ρ| ≤ 0.11	**정상.** 배율은 입력 변수로 설명하고 남은 값이라 상관이 없어야 합니다

2-8. 청년 비율과 소비 추세



- 청년비율이 0.2인 동은 연 +4%p 수준으로 개선되고, 0.5 이상인 동은 연 −8%p 이상 악화되고 있습니다.
- 이 EDA에서 가장 강한 신호입니다. 금융MBTI(2-5)와 상권 원형(2-6) 결과가 같은 방향을 가리킵니다. **2023–2025년 서울 소비의 무게중심은 청년 원룸가에서 가족·자산가 주거지로 옮겨가고 있습니다.**

2-9. EDA 요약 & 다음 분석 제안

발견	다음 단계
정성 키워드는 51개 템플릿	동 단위 분석에는 태그·업종 공백·모델 컬럼 사용. 정성 키워드 보강이 필요하면 상위 기회 동부터 apt.wiki 단지 페이지 수집
배율·직장인구 등 강한 우편향	로그 변환, 극단 22곳은 `해석주의` 로 분리
청년·1인가구 ↔ 소비 위축 (ρ = −0.45)	추세 하락이 인구 이동 때문인지 업종 구성(유흥·배달) 변화 때문인지 업종별 지출 시계열로 분해
금융MBTI가 기회 유형을 가름	금융MBTI를 기대소비 모델의 설명변수로 넣어 잔차가 얼마나 줄어드는지 검증
직장인구 = 0 인 11개 동	원천(OA-22184) 재확인